

Cloud Provider Analytics Platform - MVP Técnico

Materia: Big Data - Primer Cuatrimestre 2026 (ITBA)

Proyecto: Cloud Provider Analytics (ETL + Streaming + Serving en Cassandra)

Entrega: Segundo Parcial (MVP Técnico)

Integrantes del Grupo

- **María Mercedes Baron** - mbaron@itba.edu.ar
- **Axel Marcelo Castro Benza** - acastrobenza@itba.edu.ar
- **Lautaro Joaquín Farías** - lfarias@itba.edu.ar
- **Nicolás Matías Kim** - nkim@itba.edu.ar
- **Andrés Podgorny** - apodgorny@itba.edu.ar

Tabla de Contenidos

1. [Guía de Inicio Rápido para Ejecución Local](#)
2. [Estructura del Proyecto y Modularización](#)
3. [Diagrama de Arquitectura \(Patrón Lambda\)](#)
4. [Decisiones de Ingeniería y Particiones](#)
5. [Estrategia de Calidad de Datos y Quarantine](#)
6. [Diseño Query-First en Cassandra](#)
7. [Evidencias de Ejecución y Resultados](#)
8. [Verificación de Idempotencia](#)

Guía de Inicio Rápido para Ejecución Local

Sigue los siguientes pasos exactos para preparar e iniciar el pipeline modular en tu entorno local:

Prerrequisitos del Sistema

Antes de comenzar, asegúrate de tener instalado en tu sistema:

- **Java JDK (versión 8, 11 o 17):** Obligatorio para ejecutar Apache Spark en modo local.
- **Docker (Desktop o Engine):** Obligatorio para ejecutar el contenedor local de Cassandra.

Paso 1: Levantar e Iniciar Cassandra

Si es la primera vez que creas el contenedor:

```
docker run --name local-cassandra -p 9042:9042 -d cassandra:latest
```

Si el contenedor ya existe en Docker (para evitar conflictos de nombre):

```
docker start local-cassandra
```

Paso 2: Crear el Entorno Virtual e Instalar Dependencias

```
# Crear entorno virtual de python
python3 -m venv venv
```

```
# Activar el entorno virtual
source venv/bin/activate
```

```
# Actualizar el gestor de paquetes pip
pip install --upgrade pip
```

```
# Instalar las librerías necesarias
pip install pyspark cassandra-driver pandas pyarrow
```

Paso 3: Ejecutar el Pipeline de Datos

Para correr el pipeline de forma correcta usando las librerías del entorno virtual:

```
# Opción A (Estando dentro del entorno activado):
```

```
python main.py
```

```
# Opción B (Desde cualquier terminal en el directorio raíz):
```

```
venv/bin/python main.py
```


1. Estructura del Proyecto y Modularización

El pipeline de procesamiento de datos ha sido modularizado para cumplir con buenas prácticas de ingeniería de software. Cada fase del data lake (Landing → Bronze → Silver → Gold → Serving) está aislada en componentes cohesivos y mantenibles:

```
tp_bigdata/
├── Docs/                # Consignas de la materia y correcciones
├── datalake/            # Data Lake unificado (Landing, Bronze, Silver, Gold, Serving)
├── checkpoints/         # Directorio de control para Spark Structured Streaming
├── venv/                # Entorno virtual de Python
├── main.py              # Orquestador del pipeline (Punto de entrada de ejecución)
├── cql_queries.cql      # Scripts CQL de base de datos Cassandra
├── src/                 # Módulos del pipeline
│   ├── __init__.py      # Inicializador de paquete Python
│   ├── config.py        # Configuración, rutas y esquemas explícitos de datos
│   ├── bronze.py        # Ingesta Batch y Streaming a Bronze
│   ├── silver.py        # Conformance, enriquecimiento de datos y desvío
│   ├── gold.py          # Generación de todos los marts analíticos (FinOps)
│   └── serving.py       # Serving distribuido en Cassandra, las 5 consultas
└── README.md            # Este documento explicativo
```

2. Diagrama de Arquitectura (Patrón Lambda)

A continuación se muestra el flujo de datos del data lake implementado. El pipeline procesa maestros vía Batch y eventos de uso near real-time vía Streaming:



3. Decisiones de Ingeniería y Particiones

Justificación de Decisiones

- **Patrón Lambda:** Permite conciliar la analítica near real-time de eventos de uso cloud con procesos batch para datos estáticos y facturación mensual. La capa batch garantiza consistencia absoluta de los datos maestros de las organizaciones, mientras que el pipeline de streaming ingesta eventos de uso continuamente para la serving layer.
- **Structured Streaming de PySpark:** Elegido por su tolerancia a fallos, soporte nativo de watermarking y facilidades para realizar deduplicación y manejo de datos tardíos (late data).
- **Cassandra como Capa de Serving (AstraDB):** Cassandra es una base de datos NoSQL columnar distribuida que funciona bajo el principio de **Query-First**. Diseñamos las claves

primarias compuestas físicamente alineadas con las consultas de negocio para evitar costosos table scans en producción.

- **Carga Distribuida Paralela (`foreachPartition`):** Para evitar el cuello de botella del Driver de Spark (antipatrón de usar `.collect()`), implementamos la escritura paralela mediante `foreachPartition` ejecutada por los Spark executors directamente a Cassandra.

Estrategia de Particionamiento en el Data Lake

Para maximizar la eficiencia en Spark y acelerar los tiempos de ejecución de las queries, aplicamos particionamientos lógicos:

- **customers_orgs (Bronze):** Particionado por `hq_region` (optimiza filtros geográficos).
- **users (Bronze):** Particionado por `role` (optimiza búsquedas de tipos de usuarios).
- **resources (Bronze):** Particionado por `service` (acelera los joins de enriquecimiento posteriores).
- **usage_events (Bronze y Silver):** Particionado por `service` y `usage_date` (reduce drásticamente la lectura de particiones durante consultas de fechas y tipos de consumo).
- **support_tickets (Bronze y Silver):** Particionado por `category` y `ticket_date` respectivamente (optimiza análisis analíticos temporales).

4. Estrategia de Calidad de Datos y Quarantine

El pipeline implementa una **zona de Quarantine** física en Parquet para aislar registros anómalos o con inconsistencias estructurales. Se evalúan **3 reglas de calidad activas**:

1. **Integridad de Eventos:** El identificador del evento (`event_id`) no puede ser nulo.
2. **Integridad Financiera:** Los incrementos de costo deben ser mayores o iguales a `-0.01` (`cost_usd_increment >= -0.01`). Los registros con costos fuera de este rango se desvían a cuarentena.
3. **Consistencia Técnica:** No se admiten registros que contengan un consumo cuantitativo (`value IS NOT NULL`) pero carezcan de una unidad de medida asociada (`unit IS NULL`).

Detección Estadística de Anomalías (IQR / P-tiles)

Para el flag de anomalías en Silver, implementamos el algoritmo de **Rango Intercuartílico (IQR / p-tiles)** dinámico en Spark SQL:

- Calculamos los percentiles 25 (Q_1) y 75 (Q_3) de `daily_cost_usd` agrupados por cada `service` usando `percentile_approx`.
- Definimos el límite superior como $Q_3 + 1.5 \times IQR$ y el inferior como $Q_1 - 1.5 \times IQR$ (con una tolerancia mínima ante varianza cero).
- Cualquier registro de consumo que supere o esté por debajo de dichos límites se marca con `anomaly_flag = True` en la zona Silver.

5. Diseño Query-First en Cassandra

Modelamos la serving layer con **3 tablas** específicas para responder a las consultas analíticas del negocio en tiempo récord:

```

CREATE KEYSPACE IF NOT EXISTS cloud_analytics
WITH replication = {'class': 'SimpleStrategy', 'replication_factor': 1};

USE cloud_analytics;

-- Tabla 1: Daily Usage by Org and Service (FinOps y GenAI)
CREATE TABLE IF NOT EXISTS org_daily_usage_by_service (
    org_id text,
    service text,
    usage_date date,
    total_cost_usd double,
    total_requests double,
    total_cpu_hours double,
    total_storage_gb_hours double,
    total_genai_tokens bigint,
    total_carbon_kg double,
    PRIMARY KEY ((org_id), service, usage_date)
) WITH CLUSTERING ORDER BY (service ASC, usage_date DESC);

-- Tabla 2: Support Tickets by Org and Date (Métricas de Soporte)
CREATE TABLE IF NOT EXISTS tickets_by_org_date (
    org_id text,
    ticket_date date,
    total_tickets bigint,
    critical_tickets_count bigint,
    avg_csat double,
    sla_breach_rate double,
    PRIMARY KEY ((org_id), ticket_date)
) WITH CLUSTERING ORDER BY (ticket_date DESC);

-- Tabla 3: Monthly Revenue by Org and Month (Facturación normalizada)
CREATE TABLE IF NOT EXISTS revenue_by_org_month (
    org_id text,
    month date,
    total_subtotal_usd double,
    total_credits_usd double,
    total_taxes_usd double,
    net_revenue_usd double,
    PRIMARY KEY ((org_id), month)
) WITH CLUSTERING ORDER BY (month DESC);

```

6. Evidencias de Ejecución y Resultados

Al ejecutar el comando `venv/bin/python main.py` en la terminal, el pipeline procesa las fuentes de datos y reporta los siguientes resultados:

Ingestas de Datos Crudos (Bronze)

- **Customers Orgs:** 80 organizaciones (particionado por `hq_region`).
- **Users:** 800 usuarios (particionado por `role`).
- **Resources:** 400 recursos (particionado por `service`).
- **Billing Monthly:** 240 facturas (particionado por `currency`).
- **Support Tickets:** 1000 tickets (particionado por `category`).
- **NPS Surveys:** 92 encuestas.
- **Marketing Touches:** 1500 toques (particionado por `channel`).

Procesamientos y Calidad de Datos (Silver y Gold)

- **Eventos Silver Validados y Conformados:** 41.015 eventos correctos.
- **Eventos Desviados a Quarantine:** 2.185 eventos corruptos (con costos anómalos o sin unidad asociada).
- **Tickets Silver Procesados:** 1.000 tickets limpios (SLA y CSAT corregidos).
- **Registro de Anomalías (IQR):** 82 anomalías de costo identificadas y catalogadas en Gold.

Estructura Física y Tamaños del Data Lake (Evidencia de Particionado)

A continuación se detalla el árbol de directorios y tamaños de almacenamiento del Data Lake (`datalake/`), demostrando la aplicación de un particionamiento sensato y optimizado para Spark SQL:


```
datalake/ (30 MB total)
├─ bronze/ (2.9 MB)
│   ├── customers_orgs/ [particionado por hq_region] (116 KB)
│   │   ├── hq_region=us-east/ (16 KB)
│   │   ├── hq_region=sa-east/ (16 KB)
│   │   └─ ...
│   ├── users/ [particionado por role] (108 KB)
│   │   ├── role=developer/ (16 KB)
│   │   ├── role=data_engineer/ (20 KB)
│   │   └─ ...
│   ├── resources/ [particionado por service] (96 KB)
│   │   ├── service=compute/ (16 KB)
│   │   └─ ...
│   ├── billing_monthly/ [particionado por currency] (60 KB)
│   │   ├── currency=USD/ (20 KB)
│   │   └─ ...
│   ├── usage_events/ [particionado por service] (2.4 MB)
│   │   ├── service=compute/ (620 KB)
│   │   ├── service=database/ (396 KB)
│   │   ├── service=storage/ (404 KB)
│   │   └─ ...
│   ├── support_tickets/ [particionado por category] (104 KB)
│   └─ marketing_touches/ [particionado por channel] (88 KB)
├─ silver/ (14 MB)
│   ├── usage_events/ [particionado por usage_date y service] (11 MB)
│   │   ├── usage_date=2025-08-31/
│   │   │   ├── service=compute/
│   │   │   └─ service=storage/
│   │   └─ ...
│   ├── support_tickets/ [particionado por ticket_date] (3.0 MB)
│   ├── billing_monthly/ [normalizado a USD] (52 KB)
│   └─ nps_surveys/ (16 KB)
├─ gold/ (492 KB)
│   ├── org_daily_usage_by_service/ (308 KB)
│   ├── revenue_by_org_month/ (24 KB)
│   ├── tickets_by_org_date/ (20 KB)
│   ├── cost_anomaly_mart/ (104 KB)
│   └─ genai_tokens_by_org_date/ (32 KB)
└─
```

- └─ quarantine/ (88 KB)
- └─ usage_events/ (88 KB)

Resultados de las Consultas sobre Cassandra (Serving Layer)

Consulta 1: Costos y requests diarios para la Org 'org_c11ertj5' y Servicio 'compute' :

Date	Service	Total Cost (USD)	Total Requests

2025-08-31	compute	170.7746	349
2025-08-30	compute	1.5982	0
2025-08-29	compute	11.0387	134
2025-08-28	compute	2.2645	0
2025-08-27	compute	31.6309	382
2025-08-26	compute	23.7311	266

Consulta 2: Top-N Servicios por costo acumulado entre el 15 y 30 de agosto para la Org 'org_c11ertj5' :

Rank	Service	Cumulative Cost (USD)

1	compute	199.2243
2	genai	124.3508
3	database	108.4585
4	storage	96.4147

Consulta 3: Evolución de tickets críticos y tasa de SLA breach por día (últimos 30 días) para 'org_c11ertj5' :

Date	Total Tickets	Critical Tkts	Avg CSAT	SLA Breach Rate

2025-08-30	1	0	3.00	0.00%
2025-08-16	1	0	3.00	0.00%
2025-08-07	1	0	5.00	100.00%
2025-08-03	1	0	2.00	0.00%

Consulta 4: Revenue mensual con créditos/impuestos normalizados a USD para 'org_c11ertj5' :

Month	Subtotal (USD)	Credits (USD)	Taxes (USD)	Net Revenue (USD)
2025-08-01	981.88	0.00	206.20	1188.08
2025-07-01	2.01	0.00	0.42	2.43
2025-06-01	1900.91	10.96	399.19	2289.13

Consulta 5: Tokens GenAI y costo estimado por día para la Org 'org_c11ertj5' :

Date	Total GenAI Tokens	Total Cost (USD)
2025-08-31	3392	31.1266
2025-08-26	761	0.1375
2025-08-25	3400	32.1182
2025-08-24	1733	16.4558
2025-08-23	3077	19.1973
... (mostrando las primeras 5 filas)		

7. Verificación de Idempotencia

El pipeline valida la idempotencia ejecutando un segundo ciclo completo de guardado en Cassandra de forma distribuida. Gracias a las claves primarias diseñadas para *Query-First*, Cassandra realiza *Upserts* atómicos manteniendo estables los recuentos:

Record counts before re-running ingestion:

- org_daily_usage_by_service: 12109
- tickets_by_org_date: 944
- revenue_by_org_month: 240

Re-running Gold to Cassandra loading...

Distributed loading to Cassandra completed successfully.

Record counts after re-running ingestion:

- org_daily_usage_by_service: 12109
- tickets_by_org_date: 944
- revenue_by_org_month: 240

SUCCESS: Idempotency OK! All table counts remain unchanged after re-run.

=== MODULAR PIPELINE COMPLETED SUCCESSFULLY ===